Co-evoluzione tra cognizione generativa, topologia e intervento correttivo in una rete sociale simulata

Relazione tecnica: giustificazione metodologica delle scelte progettuali e analisi dei risultati sperimentali

Stefano Brusco

Corso di Analisi di Social Network e Media

Corso di Laurea Magistrale in Ingegneria Informatica

Dipartimento di Ingegneria Informatica, Modellistica, Elettronica e Sistemistica (DIMES)

Università della Calabria

13 ottobre 2026

Sommario

La relazione descrive e giustifica le scelte progettuali di un framework di simulazione nel quale lo stato cognitivo di agenti generativi basati su un Large Language Model (LLM), la topologia della rete sociale e un intervento di fact-checking evolvono congiuntamente in un ciclo chiuso. Il sistema opera su un sottografo di 5 000 nodi estratto dalla rete di co-autoraggio `ogbl-collab` e combina un modello Linear Threshold esteso, modulato dalle risposte dell'LLM, un link predictor GraphSAGE che guida il rewiring a densità costante e una procedura greedy di selezione dei nodi di intervento. Per ciascun componente le scelte sono confrontate con le alternative disponibili in letteratura e nel materiale didattico del corso, esplicitando i criteri di decisione e i compromessi accettati. I risultati di una fase di co-evoluzione di 100 step e di un esperimento accoppiato intervento/controllo di 30 step mostrano: *(i)* una dinamica di diffusione descritta da una curva logistica ($R^2 = 0.997$) con saturazione al 40.5% della popolazione; *(ii)* un incremento della belief assortativity da 0.268 a 0.659 (+145.5%) a fronte di un incremento dell'Echo Chamber Index strutturale del 5.0%; *(iii)* un effetto dell'intervento con 20 fact-checker pari a +160 nodi resistenti rispetto al controllo, in accordo con la stima ex ante di 162 nodi, e un effetto sulla popolazione infetta (-4 nodi) non distinguibile dalla variabilità spontanea della dinamica.

Indice

1 Introduzione **3**
- 1.1 Inquadramento del problema . . . 3
- 1.2 Obiettivi e domande di ricerca . . . 3
- 1.3 Struttura del documento . . . 3

2 Fondamenti teorici **4**
- 2.1 Modelli di diffusione e massimizzazione dell'influenza . . . 4
- 2.2 Modelli epidemici . . . 4
- 2.3 Omofilia e assortatività . . . 4
- 2.4 Modularità . . . 5
- 2.5 Graph Neural Network . . . 5

3 Scelte architetturali **5**
- 3.1 Requisiti che determinano l'architettura . . . 5
- 3.2 Organizzazione su tre livelli in ciclo chiuso . . . 5
- 3.3 L'embedding come canale di accoppiamento . . . 6
- 3.4 Componenti software e flusso dei dati . . . 7
- 3.5 Infrastruttura di inferenza . . . 8

4 Selezione degli algoritmi e confronto con le alternative **9**
- 4.1 Campionamento del sottografo: Forest Fire . . . 9
- 4.2 Rilevamento delle comunità: Label Propagation . . . 9
- 4.3 Selezione dei pazienti zero: centralità combinata . . . 10
- 4.4 Modello di diffusione: Linear Threshold esteso con modulazione cognitiva . . . 10
- 4.5 Rappresentazione e link prediction: GraphSAGE . . . 11
- 4.6 Rewiring a densità costante . . . 13
- 4.7 Selezione dei fact-checker: greedy esatto su obiettivo a soglia . . . 13
- 4.8 Metriche di segregazione . . . 15

5 Disegno sperimentale **15**
- 5.1 Fasi e parametri . . . 15
- 5.2 Disegno accoppiato intervento/controllo . . . 16

6 Risultati e discussione **16**
- 6.1 Validazione del campionamento . . . 16
- 6.2 Dinamica di diffusione (Fase 2) . . . 17
- 6.3 Co-evoluzione e segregazione (Fase 2) . . . 18
- 6.4 Effetto dell'intervento (Fase 3) . . . 20
- 6.5 Prestazioni computazionali . . . 22
- 6.6 Minacce alla validità . . . 22

7 Conclusioni e sviluppi futuri **23**

1 Introduzione

1.1 Inquadramento del problema

La formazione di *echo chamber*, ossia di gruppi di individui densamente connessi che condividono la medesima posizione su un tema, costituisce uno dei fenomeni più studiati nell'analisi delle reti sociali online [5]. La letteratura sull'omofilia distingue due meccanismi che possono produrre la correlazione osservata tra legami e opinioni [21, 1]: la *selezione*, per cui gli individui stabiliscono o mantengono legami con soggetti simili, e l'*influenza sociale*, per cui gli individui modificano le proprie caratteristiche mutabili per allinearsi a quelle dei vicini. Nei sistemi reali i due meccanismi agiscono simultaneamente: la topologia condiziona la diffusione delle opinioni e la distribuzione delle opinioni condiziona l'evoluzione della topologia. Si parla in questo caso di *co-evoluzione* tra rete e stati dei nodi [11].

I modelli classici trattano di norma i due processi in modo separato. I modelli di diffusione e di massimizzazione dell'influenza (Independent Cascade, Linear Threshold) [13] assumono un grafo statico; i modelli co-evolutivi di tipo Holme–Newman [11] rappresentano l'opinione come variabile categoriale aggiornata da regole elementari. In entrambi i casi la risposta individuale all'esposizione è ridotta a un parametro scalare (una probabilità di attivazione o una soglia). La disponibilità di agenti generativi basati su LLM [25] consente di sostituire tale parametro con una valutazione del contenuto effettivamente osservato dall'agente, condizionata da un profilo comportamentale e dallo stato corrente.

Il progetto oggetto della relazione integra i due processi e un terzo elemento, l'intervento esterno di fact-checking, in un unico ciclo di aggiornamento. Il problema affrontato è pertanto la costruzione e la valutazione di un sistema dinamico in cui:

- lo stato cognitivo degli agenti (opinione testuale, suscettibilità, stato discreto) è prodotto da un LLM a partire dal contenuto pubblicato dai vicini;
- la topologia è aggiornata da un link predictor che opera su rappresentazioni vettoriali perturbate dalle transizioni di stato;
- l'intervento seleziona, con budget fissato, i nodi da convertire in fact-checker sulla base dello stato corrente della rete.

1.2 Obiettivi e domande di ricerca

Gli obiettivi del lavoro sono tre: *(O1)* realizzare un'architettura in cui i tre livelli (cognitivo, strutturale, di intervento) siano accoppiati in ciclo chiuso e non eseguiti come fasi indipendenti; *(O2)* misurare l'evoluzione della segregazione della rete distinguendo la componente strutturale da quella di opinione; *(O3)* stimare l'effetto causale di un intervento a budget limitato mediante un confronto con una simulazione di controllo. Gli obiettivi si traducono nelle seguenti domande di ricerca:

RQ1 La dinamica di diffusione prodotta da agenti LLM accoppiati a un meccanismo a soglia presenta regolarità quantitative confrontabili con i modelli epidemici e di soglia classici?

RQ2 La co-evoluzione tra opinioni e topologia incrementa la segregazione della rete, e in quale misura tale incremento riguarda la struttura comunitaria rispetto alla distribuzione delle opinioni?

RQ3 Un intervento con budget pari allo 0.4% dei nodi, selezionato massimizzando la copertura immediata, modifica la dinamica rispetto al controllo, e su quali popolazioni di agenti?

1.3 Struttura del documento

La Sezione 2 richiama i fondamenti teorici utilizzati nelle giustificazioni successive. La Sezione 3 descrive e motiva l'architettura. La Sezione 4 confronta ciascun algoritmo adottato con le

alternative. La Sezione 5 illustra il disegno sperimentale. La Sezione 6 analizza i risultati e le prestazioni, discutendo le minacce alla validità. La Sezione 7 riassume le risposte alle domande di ricerca e gli sviluppi previsti.

2 Fondamenti teorici

2.1 Modelli di diffusione e massimizzazione dell'influenza

Dato un grafo $G = (V, E)$ e un modello di diffusione $\mathcal{M}$, lo *spread* di un insieme di seed $S \subseteq V$ è il valore atteso della cardinalità dell'insieme attivo finale, $\sigma_{G,\mathcal{M}}(S) = \mathbb{E}\,|\varphi(S)|$. Il problema di Influence Maximization (IM) richiede di determinare $S^* = \arg\max_{|S|\le k} \sigma(S)$ [13, 1].

Nel modello *Independent Cascade* (IC) ogni nodo attivato u dispone di un unico tentativo indipendente di attivare ciascun vicino v, con probabilità p_{uv}. Nel modello *Linear Threshold* (LT) a ogni arco è associato un peso w_{uv} con $\sum_u w_{uv} \le 1$, a ogni nodo una soglia $\theta_v \sim \mathcal{U}[0,1]$, e un nodo inattivo si attiva quando $\sum_{u \in N(v) \cap A_{t-1}} w_{uv} \ge \theta_v$. I due modelli non sono equivalenti: con due vicini attivi x, y, un nodo z si attiva con probabilità $1-(1-p_{xz})(1-p_{yz})$ in IC e $w_{xz} + w_{yz}$ in LT [1]. Il modello *General Threshold* (GT) generalizza LT sostituendo la somma con una funzione di soglia monotona arbitraria f_v.

Il problema IM è NP-hard sotto IC e LT e il calcolo esatto di $\sigma(S)$ è #P-hard. Se σ è monotona e submodulare, cioè

$$\sigma(S \cup \{v\}) - \sigma(S) \;\ge\; \sigma(S' \cup \{v\}) - \sigma(S') \qquad \forall\, S \subseteq S' \subseteq V,\; v \notin S', \tag{1}$$

l'algoritmo greedy garantisce $\sigma(S_{\text{greedy}}) \ge (1 - 1/e)\,\sigma(S^*)$ [22]. Kempe et al. [13] dimostrano che la funzione di spread è submodulare sotto IC e sotto LT *con soglie uniformi in* $[0,1]$; la proprietà non vale, in generale, per i modelli GT [1]. L'algoritmo CELF [18] sfrutta la (1): il guadagno marginale calcolato in un'iterazione precedente è un limite superiore del guadagno corrente, e ciò consente la valutazione *lazy* dei candidati tramite una coda di priorità. La correttezza di tale potatura dipende integralmente dalla submodularità.

2.2 Modelli epidemici

I modelli compartimentali descrivono l'evoluzione dei valori attesi delle popolazioni suscettibile (S), infetta (I) e recuperata (R) [14, 1]. Nel modello SI la frazione di infetti segue la curva logistica

$$i(t) = \frac{i_0\, e^{\beta t}}{1 + i_0\,(e^{\beta t} - 1)}, \tag{2}$$

che tende a 1: in assenza di un meccanismo di uscita dallo stato infetto l'intera popolazione viene contagiata. Nel modello SIR il compartimento R sottrae individui al processo e il picco di infezione si mantiene lontano dalla saturazione. L'immunizzazione, intesa come rimozione preventiva di suscettibili dal processo, è tanto più efficace quanto più è mirata ai nodi strutturalmente rilevanti [26].

2.3 Omofilia e assortatività

Il test di omofilia riportato in [1] considera una caratteristica binaria posseduta da una frazione p dei nodi: in assenza di omofilia la frazione attesa di archi tra nodi con valori diversi è $2pq$, con $q = 1 - p$; una frazione osservata significativamente inferiore costituisce evidenza di omofilia. Per una variabile con c categorie di frequenza $p_1, \dots, p_c$ la generalizzazione immediata è

$$H_0 = \sum_{s=1}^{c} p_s^2, \qquad 1 - H_0 = \Pr[\text{arco tra categorie diverse} \mid \text{assegnazione casuale}], \tag{3}$$

che per $c = 2$ restituisce $1 - H_0 = 2pq$. Il coefficiente di assortatività di Newman [23] misura invece la correlazione di Pearson tra i valori ai due estremi degli archi e incorpora per costruzione la correzione rispetto all'assegnazione casuale.

2.4 Modularità

Data una partizione $\mathcal{C}$, la modularità confronta la densità interna delle comunità con quella attesa in un modello nullo che preserva i gradi [24]:

$$Q(G, \mathcal{C}) = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j). \tag{4}$$

L'ottimizzazione di Q soffre di un limite di risoluzione, per cui comunità piccole tendono a essere fuse in comunità più grandi [6].

2.5 Graph Neural Network

Nelle GNN ogni nodo calcola la propria rappresentazione aggregando quelle dei vicini. Lo schema di base presentato in [1] è

$$h_v^k = \sigma\left(W_k \sum_{u \in N(v)} \frac{h_u^{k-1}}{|N(v)|} + B_k \, h_v^{k-1} \right), \qquad h_v^0 = x_v, \tag{5}$$

con matrici W_k e B_k condivise tra tutti i nodi dello stesso layer. Poiché i parametri non dipendono dall'identità dei nodi, un modello addestrato su un grafo può essere applicato a un grafo diverso: è questa la proprietà di *induttività* che distingue le GNN dagli embedding *shallow*, i quali associano un vettore libero a ogni nodo [10, 1].

3 Scelte architetturali

3.1 Requisiti che determinano l'architettura

L'architettura discende da cinque requisiti, ciascuno dei quali è riconducibile agli obiettivi della Sezione 1:

R1 *Accoppiamento bidirezionale*: ogni transizione di stato deve poter modificare la topologia dello step successivo e ogni modifica topologica deve modificare l'informazione percepita dagli agenti (O1).

R2 *Trattabilità dell'inferenza*: il numero di invocazioni dell'LLM per step deve essere compatibile con le risorse disponibili (due GPU NVIDIA T4 in sessioni di 12 ore).

R3 *Confrontabilità*: due simulazioni avviate dallo stesso stato devono differire solo per il trattamento applicato (O3).

R4 *Resilienza*: l'esecuzione deve poter essere interrotta e ripresa senza alterare la traiettoria della simulazione.

R5 *Misurabilità*: a ogni step devono essere registrate metriche strutturali e di opinione su una base di riferimento costante (O2).

3.2 Organizzazione su tre livelli in ciclo chiuso

Il sistema è organizzato su tre livelli (Figura 1). Il *livello cognitivo* comprende gli agenti generativi e la macchina a stati che ne governa le transizioni; il *livello strutturale* comprende il link predictor GraphSAGE e il rewiring del grafo; il *livello di intervento* comprende la

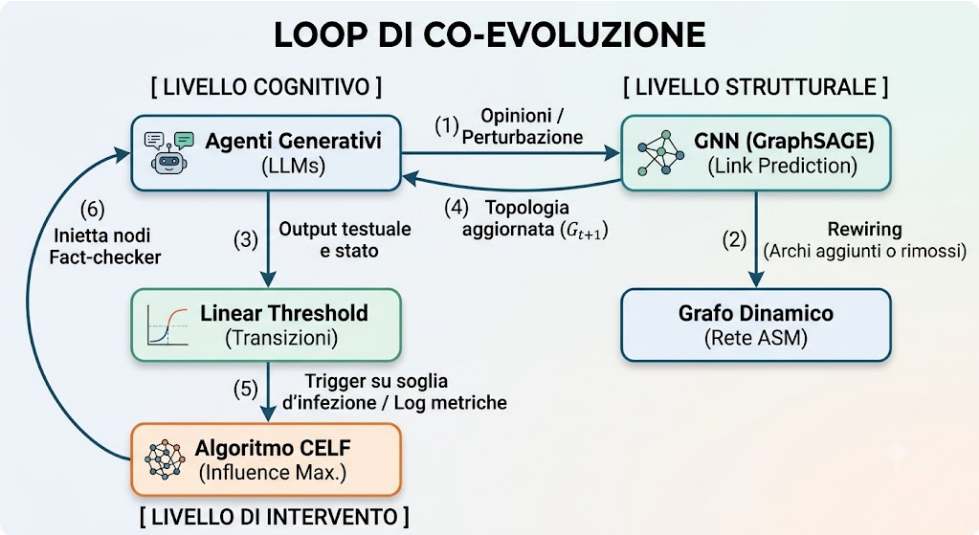


Figura 1: Schema del ciclo di co-evoluzione. Le transizioni prodotte dal livello cognitivo perturbano gli embedding (1); il link predictor determina il rewiring (2); la topologia aggiornata G_{t+1} definisce il vicinato e il feed dello step successivo (4); le transizioni alimentano la condizione di attivazione dell'intervento (5), che inietta i fact-checker nella rete (6). Il blocco indicato come CELF corrisponde al modulo di selezione `celf.py`; nell'esperimento è stato utilizzato l'obiettivo a soglia descritto nella Sezione 4.7.

selezione dei fact-checker e la loro iniezione. Il requisito R1 esclude una pipeline sequenziale nella quale la diffusione venga simulata su un grafo fisso e il rewiring applicato a posteriori: in tale schema le due dinamiche non interagirebbero e non sarebbe possibile osservare gli effetti di retroazione oggetto di studio. L'unità atomica dell'esecuzione è quindi lo step co-evolutivo descritto dall'Algoritmo 1.

L'ordine delle operazioni (agenti, link predictor, rewiring) segue la catena causale del modello: la topologia dello step $t + 1$ deve riflettere le opinioni prodotte allo step t, e il link predictor deve essere aggiornato sulle rappresentazioni già perturbate. Due scelte di dettaglio meritano una giustificazione esplicita.

Aggiornamento sincrono. Tutti gli agenti attivi allo step t leggono la medesima istantanea dello stato. Nell'aggiornamento asincrono, adottato nella prima versione del codice, un agente elaborato più tardi nell'ordinamento casuale poteva osservare gli effetti di agenti già aggiornati nello stesso step, rendendo la dinamica dipendente dall'ordine di elaborazione. L'aggiornamento sincrono elimina tale dipendenza ed è inoltre la condizione che consente di inviare le richieste all'LLM in parallelo senza condizioni di competizione sullo stato del grafo.

Attivazione parziale. A ogni step viene attivato il 15% dei nodi. La scelta riduce di un fattore $1/\rho \approx 6.7$ il numero di invocazioni dell'LLM per step (R2) e rappresenta l'eterogeneità dell'attività degli utenti, che non interagiscono tutti con la medesima frequenza. Ne consegue che il tempo di attesa di un nodo prima di essere valutato segue una distribuzione geometrica di parametro ρ; tale proprietà è utilizzata nella Sezione 6.4 per interpretare la dinamica temporale dell'intervento.

3.3 L'embedding come canale di accoppiamento

Il requisito R1 richiede un canale attraverso cui le opinioni influenzino la topologia. Il canale adottato è il vettore di feature del nodo, inizializzato con l'embedding Word2Vec a 128 dimensioni fornito da `ogbl-collab` [12], che rappresenta i temi di ricerca dell'autore. A ogni transizione

Algoritmo 1 Step co-evolutivo t (modulo `orchestrator.py`)

Input: grafo G_t, stati x_t, embedding Z_t, parametri del link predictor Θ_t
Output: G_{t+1}, x_{t+1}, Z_{t+1}, Θ_{t+1} e metriche dello step

$A_t \leftarrow$ sottoinsieme casuale di $\lfloor \rho\, n \rfloor$ nodi, $\rho = 0.15$ ▷ attivazione parziale
$\hat{x} \leftarrow x_t$ ▷ istantanea unica: aggiornamento sincrono
for all $v \in A_t$ **do** ▷ PREPARE, solo letture
    costruisci il prompt da persona, stato $\hat{x}_v$, centralità e ultimi post dei vicini
end for
invia in parallelo le richieste all'LLM e raccogli $o_v = (s_v, \pi_v, \iota_v)$ ▷ DISPATCH
if la quota di risposte fallite supera 0.5 **then**
    interrompi lo step senza modificare lo stato
end if
for all $v \in A_t$ **do** ▷ FINALIZE, scritture
    $x_{t+1}(v) \leftarrow \Phi(\hat{x}_v,\, f_v^I,\, f_v^F,\, o_v)$ ▷ LT esteso, Tabella 4
    pubblica il post di v; accumula Δz_v secondo l'Eq. (6)
end for
$Z_{t+1} \leftarrow Z_t + \Delta Z$ ▷ aggiornamento vettorizzato
$\Theta_{t+1} \leftarrow$ 15 epoche di Adam sul task di link prediction in (G_t, Z_{t+1})
if $t \bmod 2 = 0$ **then**
    $G_{t+1} \leftarrow \textsc{Rewire}(G_t, \Theta_{t+1}, Z_{t+1})$
else
    $G_{t+1} \leftarrow G_t$
end if
calcola e registra le metriche; salva il checkpoint

verso lo stato $x \in \{I, R, F\}$ il vettore è perturbato lungo una direzione ideologica:

$$\Delta z_v = \eta \left| s_v - \tfrac{1}{2} \right| \operatorname{sgn}(x)\, d_v, \qquad d_v = \frac{d + 0.1\, \varepsilon_v}{\| d + 0.1\, \varepsilon_v \|}, \qquad \eta = 0.05, \tag{6}$$

dove $s_v \in [0, 1]$ è la suscettibilità dichiarata dall'LLM, $\operatorname{sgn}(I) = +1$, $\operatorname{sgn}(R) = \operatorname{sgn}(F) = -1$, d è una direzione condivisa da tutti gli agenti ed ε_v una componente individuale. La direzione condivisa è necessaria affinché agenti nello stesso stato si avvicinino nello spazio vettoriale: con direzioni indipendenti per agente, adottate in una versione precedente, la similarità tra embedding non rifletteva la vicinanza di opinione e il rewiring risultava scorrelato dalle opinioni. La componente individuale (10%) preserva l'eterogeneità dei nodi; l'ampiezza proporzionale a $|s_v - 1/2|$ fa sì che le transizioni dichiarate con maggiore convinzione producano spostamenti maggiori.

L'alternativa di introdurre l'opinione come feature categoriale esplicita del link predictor è stata scartata perché avrebbe reso il rewiring una regola deterministica sullo stato discreto, eliminando il contributo dell'informazione semantica e strutturale contenuta negli embedding originali.

3.4 Componenti software e flusso dei dati

- `NetworkManager`: unico punto di accesso in lettura e scrittura a grafo, stati, post ed embedding. La centralizzazione garantisce che ogni modulo osservi uno stato coerente e che il checkpoint contenga l'intero stato della simulazione (R4).
- `SimulationOrchestrator`: esegue l'Algoritmo 1 in tre fasi (PREPARE sequenziale, DISPATCH parallelo su un pool di thread, FINALIZE sequenziale). Il controllo sulla quota di risposte fallite è posto prima di qualsiasi scrittura, così che un'interruzione del server LLM non produca step registrati con agenti inerti.

- `CheckpointManager`: serializza a ogni step grafo, stati, embedding, pesi del link predictor e stato dell'ottimizzatore Adam. La persistenza dello stato dell'ottimizzatore è necessaria affinché una run suddivisa in più sessioni coincida con una run continua; le soglie individuali sono funzione deterministica di (seed, identificativo del nodo) e non dell'ordine di interrogazione, per la medesima ragione.
- `config.yaml`: unica sorgente dei parametri, con hash registrato in ogni report per la tracciabilità (R5).
- **Client LLM**: gestisce retry con backoff esponenziale, validazione dell'output JSON, cache su disco e un seed per richiesta derivato dal contenuto del prompt. Quest'ultimo elemento rende identiche, a parità di prompt, le risposte ricevute da due simulazioni distinte, ed è il presupposto del disegno accoppiato descritto nella Sezione 5 (R3).

3.5 Infrastruttura di inferenza

La Tabella 1 confronta le opzioni di inferenza considerate. Il carico atteso è dell'ordine di 750 richieste per step (15% di 5 000 nodi), ridotto dalla regola che omette l'invocazione per i nodi suscettibili privi di vicini infetti o fact-checker.

Tabella 1: Alternative per l'inferenza dell'LLM.

Criterio	**API cloud (Gemini)**	**Server locale sequenziale (Ollama)**	**Server locale con batching (vLLM, adottato)**
Throughput	Limitato dai rate limit del fornitore	Una richiesta alla volta	Continuous batching e PagedAttention [16]; fino a 150 richieste concorrenti
Costo	Proporzionale ai token	Nullo	Nullo (GPU della piattaforma)
Riproducibilità	Versione del modello remota e non controllabile	Controllabile	Versioni delle librerie fissate; seed per richiesta
Vincoli hardware	Nessuno	GPU locale	Modello quantizzato a 4 bit (AWQ [20]) su T4, parallelismo tensoriale su due GPU

Il modello adottato è Llama 3 8B Instruct [8] quantizzato AWQ, con temperatura 0.7. La quantizzazione a 4 bit riduce l'occupazione dei pesi a circa un quarto rispetto alla precisione a 16 bit e lascia nella memoria di una T4 (16 GB) lo spazio per la cache delle chiavi e dei valori richiesta dal batching di molte richieste concorrenti. Un modello della classe da 8 miliardi di parametri rappresenta un compromesso tra la capacità di seguire istruzioni con output strutturato e il throughput necessario per circa 750 richieste per step. La temperatura non nulla introduce variabilità comportamentale tra agenti in contesti simili; la riproducibilità tra run è garantita dal seed per richiesta anziché dall'azzeramento della temperatura, che avrebbe reso le risposte deterministiche ma anche meno eterogenee.

Ogni agente riceve un prompt di sistema che ne definisce il profilo (quattro archetipi: scettico, conformista, pragmatico, attivista, assegnati in base alla comunità di appartenenza), lo stato corrente, il livello di influenza e il tema della simulazione, e restituisce un oggetto JSON con i campi `opinion`, `susceptibility`, `proposed_state` e `spread_intent`. Il formato strutturato è necessario perché l'output dell'LLM deve essere convertito in grandezze numeriche utilizzabili dalla macchina a stati.

4 Selezione degli algoritmi e confronto con le alternative

Per ciascun componente si riportano i criteri di selezione, le alternative considerate e le ragioni della scelta, distinguendo gli argomenti teorici da quelli legati ai vincoli computazionali.

4.1 Campionamento del sottografo: Forest Fire

La simulazione con un LLM per nodo non è praticabile sull'intera rete `ogbl-collab` [12] (235 868 nodi); è quindi necessario estrarre un sottografo di 5 000 nodi che conservi le proprietà rilevanti per i fenomeni studiati: distribuzione dei gradi a coda pesante (che determina il ruolo degli hub nella diffusione), coefficiente di clustering (che determina la disponibilità di chiusure triadiche per il rewiring) e struttura comunitaria (che costituisce il riferimento per le metriche di segregazione).

Tabella 2: Strategie di campionamento disponibili nel modulo `extractor.py`.

Strategia	**Comportamento atteso**	**Esito rispetto ai requisiti**
Random Node	Nodi estratti uniformemente; sottografo indotto	Grado medio ridotto di circa il fattore di campionamento ($\approx 2\%$); sottografo frammentato: inadatto alla diffusione
BFS da hub	Esplorazione in ampiezza dal nodo di grado massimo	Sovrarappresentazione del nucleo denso attorno al seme; periferia assente
Random Walk con restart	Visita proporzionale al grado	Distorsione verso nodi ad alto grado; dipendenza dal seme
Forest Fire (adottato)	Propagazione con numero di vicini «bruciati» $\sim \text{Geom}(1 - p_f)$, $p_f = 0.5$	Tra i metodi con le prestazioni migliori nella preservazione congiunta di distribuzione dei gradi, clustering e struttura locale [17]

La scelta di Forest Fire si fonda sull'evidenza sperimentale di Leskovec e Faloutsos [17], secondo cui il metodo è tra quelli che approssimano meglio, congiuntamente, le proprietà statiche del grafo originale; rispetto al random walk, inoltre, la propagazione per «incendi» successivi riduce la dipendenza dal nodo di partenza. Il parametro $p_f = 0.5$ si colloca nell'intervallo previsto dalla configurazione del progetto (0.4–0.7): valori maggiori producono sottografi più densi e localizzati. La verifica empirica sul dataset effettivo è riportata nella Sezione 6.1.

4.2 Rilevamento delle comunità: Label Propagation

Le comunità individuate in Fase 0 svolgono due funzioni: costituiscono la partizione di riferimento $\mathcal{C}_0$ rispetto alla quale sono calcolati modularità ed Echo Chamber Index in ogni step, e determinano il profilo assegnato agli agenti. La Tabella 3 confronta le alternative trattate nel corso.

Tabella 3: Algoritmi di community detection considerati.

Algoritmo	**Costo**	**Proprietà rilevanti**
Girvan–Newman (betweenness)	$O(m^2 n)$	Ricalcolo iterato della betweenness: non praticabile su 2.3×10^5 nodi
Louvain [2]	$O(n \log n)$	Ottimizzazione greedy di Q; limite di risoluzione [6]; degenerazione dei massimi locali
Label Propagation [27] (adottato)	$\approx O(m)$	Privo di parametri; nessuna funzione obiettivo globale; non deterministico

La Label Propagation è stata preferita per il costo quasi lineare, che ne consente l'applicazione anche al grafo completo nella fase di validazione, e per l'assenza di parametri di risoluzione, che evita di introdurre un ulteriore grado di libertà nella definizione delle metriche di segregazione. Il principale svantaggio, il non determinismo, è neutralizzato dalla memorizzazione della partizione su disco: la partizione è calcolata una sola volta e riutilizzata in tutte le esecuzioni. Sul sottografo la partizione ottenuta presenta 415 comunità e $Q = 0.8265$, valore che ne conferma l'adeguatezza come riferimento.

La partizione $\mathcal{C}_0$ non viene ricalcolata durante la simulazione. Un ricalcolo a ogni step renderebbe le metriche dipendenti sia dalla dinamica sia dalle fluttuazioni dell'algoritmo di partizionamento, e i valori non sarebbero confrontabili nel tempo. Con la partizione fissata, una variazione di Q o dell'ECI misura esclusivamente lo spostamento degli archi rispetto a una struttura comunitaria costante.

4.3 Selezione dei pazienti zero: centralità combinata

I nodi inizialmente infetti (15% della rete, 750 nodi) sono selezionati con un punteggio combinato $c(v) = 0.4\,\widehat{\mathrm{PR}}(v) + 0.4\,\widehat{\mathrm{Katz}}(v) + 0.2\,\widehat{\deg}(v)$, con punteggi normalizzati, PageRank con $\alpha = 0.85$ e Katz con $\alpha = 0.01$. Le alternative disponibili sono le singole centralità, la betweenness, una selezione casuale e una selezione stratificata per comunità.

La scelta non costituisce un problema di ottimizzazione ma la definizione dello scenario: si modella una narrazione che ha origine da nodi centrali, condizione che rappresenta il caso sfavorevole per il contenimento. In questo contesto le misure di centralità operano come *proxy* di influenza [1], efficienti ma prive di garanzie teoriche. La combinazione lineare attenua le distorsioni delle singole misure: il grado considera solo il vicinato immediato, il PageRank l'importanza ricorsiva dei vicini, la centralità di Katz la totalità dei cammini con attenuazione geometrica. La betweenness è stata esclusa per il costo $O(nm)$ e perché misura la funzione di intermediazione più che la capacità di esposizione diretta.

4.4 Modello di diffusione: Linear Threshold esteso con modulazione cognitiva

Definizione. Siano $f_v^I = |N(v) \cap I| / \deg(v)$ e $f_v^F = |N(v) \cap F| / \deg(v)$ le frazioni di vicini infetti e fact-checker del nodo v. Ogni nodo possiede una soglia base $\theta_v \sim \mathcal{N}(0.3,\, 0.1^2)$, troncata in $[0.05, 0.95]$ e funzione deterministica di (seed, v). La soglia efficace è modulata dalla suscettibilità restituita dall'LLM:

$$\theta_v^{\mathrm{eff}} = \mathrm{clip}\big(\theta_v\,(1.5 - s_v),\ 0.05,\ 0.99\big), \tag{7}$$

e varia quindi tra $0.5\,\theta_v$ (suscettibilità massima) e $1.5\,\theta_v$ (suscettibilità nulla). Le regole di transizione sono riportate nella Tabella 4; le condizioni sono valutate nell'ordine indicato.

Tabella 4: Regole della macchina a stati (π_v: stato proposto dall'LLM; ι_v: intenzione di diffusione).

Transizione	Condizione	Interpretazione
$S \to R$	$f_v^F \geq 0.10 \ \wedge \ f_v^F \geq f_v^I \ \wedge \ \pi_v \neq I$	Inoculazione da fact-checking
$S \to I$	$f_v^I \geq \theta_v^{\text{eff}} \ \wedge \ \pi_v = I$	Contagio a soglia
$S \to R$	$\neg\iota_v \ \wedge \ f_v^I \geq 0.12 \ \wedge \ s_v < 0.5$	Resistenza attiva dopo esposizione
$I \to R$	$f_v^F \geq 0.25 \ \vee \ \pi_v = R$	Correzione esterna o autocorrezione
$R \to I$	$f_v^I \geq 0.6 \ \wedge \ s_v > 0.8 \ \wedge \ \pi_v = I$	Ricaduta (evento raro)
$F \to F$	sempre	Stato assorbente

Collocazione rispetto ai modelli classici. Ponendo $w_{uv} = 1/\deg(v)$, la frazione f_v^I coincide con la somma dei pesi dei vicini attivi del modello LT, e il vincolo $\sum_u w_{uv} \leq 1$ è soddisfatto con uguaglianza. Il modello si discosta tuttavia da LT in quattro aspetti: *(a)* le soglie non sono uniformi in $[0, 1]$; *(b)* la soglia efficace varia nel tempo in funzione dell'output dell'LLM; *(c)* il contagio richiede la congiunzione tra pressione strutturale e assenso cognitivo; *(d)* la dinamica non è progressiva, poiché sono ammesse le uscite dallo stato infetto e la ricaduta. Il modello appartiene pertanto alla famiglia General Threshold con dinamica non monotona, per la quale i risultati di submodularità di [13] non sono applicabili. La conseguenza di questo inquadramento sulla scelta dell'algoritmo di intervento è discussa nella Sezione 4.7.

Confronto con le alternative.

- *Independent Cascade.* IC descrive un contagio «semplice», in cui una singola esposizione è sufficiente all'attivazione. L'adozione di un'opinione polarizzante è invece assimilabile a un contagio «complesso», che richiede il rinforzo di più fonti indipendenti [4]; i modelli a soglia rappresentano direttamente questo requisito [7].
- *Modelli compartimentali SIR/SIRS.* Descrivono valori attesi in ipotesi di mescolamento omogeneo e non utilizzano la topologia [1], che nel presente lavoro è invece la variabile di interesse. Dalla famiglia SIR è stata ripresa la struttura a compartimenti, estesa con lo stato F.
- *LT classico con soglia fissa.* Riduce l'eterogeneità individuale a un parametro scalare. La modulazione tramite LLM introduce una dipendenza della soglia dal contenuto effettivamente letto e dal profilo dell'agente, informazione non riducibile a una costante.

La regola congiuntiva per $S \to I$ assegna all'LLM una funzione di consenso e non di generazione autonoma del contagio: un agente privo di esposizione sufficiente non può infettarsi anche qualora l'LLM lo proponga. La scelta limita l'impatto di eventuali risposte incoerenti del modello linguistico sulla dinamica complessiva e mantiene la struttura della rete come condizione necessaria della diffusione.

4.5 Rappresentazione e link prediction: GraphSAGE

Modello adottato. Il link predictor è una rete GraphSAGE a due layer con aggregatore di media [10]:

$$h_v^1 = \text{ReLU}\Big(W_1\big[\, z_v \,\|\, \tfrac{1}{|N(v)|}\textstyle\sum_{u\in N(v)} z_u\big] + b_1\Big), \tag{8}$$

$$h_v^2 = W_2\big[\, h_v^1 \,\|\, \tfrac{1}{|N(v)|}\textstyle\sum_{u\in N(v)} h_u^1\big] + b_2, \tag{9}$$

$$\hat{h}_v = \sqrt{\gamma}\; h_v^2/\|h_v^2\|, \qquad \text{score}(u,v) = \sigma\big(\hat{h}_u^\top \hat{h}_v\big) = \sigma\big(\gamma\cos(h_u^2, h_v^2)\big), \tag{10}$$

con dimensione nascosta e di output pari a 128 e scala γ appresa (valore iniziale 5, massimo 100). La concatenazione $W[\, z_v \,\|\, \bar{z}_{N(v)}]$ equivale alla somma $W^{\text{self}} z_v + W^{\text{neigh}} \bar{z}_{N(v)}$ e corrisponde

quindi allo schema (5) con matrici distinte per il nodo e per il vicinato. L'addestramento minimizza l'entropia incrociata binaria su un massimo di 8 192 archi esistenti (positivi) e un pari numero di coppie non connesse campionate casualmente (negativi), con Adam ($\eta = 10^{-3}$) per 15 epoche per step, a partire dai parametri dello step precedente.

Due accorgimenti derivano da difetti osservati in versioni precedenti: l'ultimo layer è lineare, poiché con attivazione ReLU e normalizzazione L_2 i prodotti scalari risultavano confinati in $[0, 1]$ e gli score in $[0.50, 0.73]$; la scala γ è appresa, poiché con norma unitaria gli score restavano compresi in $[0.27, 0.73]$ e non consentivano di separare positivi e negativi.

Tabella 5: Alternative per la rappresentazione dei nodi e la link prediction.

Metodo	**Induttivo**	**Usa le feature**	**Limite rispetto al problema**
Euristiche (vicini comuni, Adamic–Adar) [19]	n.a.	no	Puramente strutturali: le opinioni non influenzerebbero il rewiring, violando R1
Embedding shallow (node2vec) [9]	no	no	$O(\|V\|d)$ parametri; riaddestramento a ogni modifica topologica [1]
GCN [15]	parziale	sì	Normalizzazione simmetrica con self-loop: stessa matrice per nodo e vicini; formulazione originale trasduttiva
GAT [30]	sì	sì	Coefficienti di attenzione per arco: costo e numero di parametri superiori a parità di dimensione
GraphSAGE [10] (adottato)	sì	sì	Nessun limite sostanziale alla scala considerata

Motivazione. Tre argomenti sostengono la scelta.

1. *Uso delle feature come canale di accoppiamento.* Le opinioni raggiungono il livello strutturale esclusivamente attraverso la perturbazione degli embedding (Eq. (6)). Le euristiche strutturali e gli embedding shallow ignorano le feature dei nodi e renderebbero il rewiring indipendente dalle opinioni.

2. *Induttività.* Il grafo cambia a ogni step di rewiring e le feature cambiano a ogni step. Un modello induttivo consente l'aggiornamento incrementale (*warm start*) dei parametri, con un costo di 15 epoche per step, mentre un metodo trasduttivo richiederebbe un riaddestramento completo.

3. *Separazione tra contributo del nodo e del vicinato.* Il segnale di opinione risiede nell'embedding del nodo stesso. La formulazione GraphSAGE mantiene matrici distinte per il nodo e per il vicinato, e il modello può quindi pesare in modo differente la posizione individuale e quella del contesto; nella GCN entrambi i contributi condividono la stessa trasformazione.

Rispetto a GAT la scelta è motivata da un criterio di parsimonia: con 15 epoche per step su 100 step complessivi, il costo aggiuntivo dell'attenzione non è giustificato da un requisito di interpretabilità per arco, che non rientra negli obiettivi del lavoro. L'implementazione aggrega l'intero vicinato tramite moltiplicazione per la matrice di adiacenza sparsa normalizzata, senza il campionamento dei vicini previsto dalla formulazione originale: con 5 000 nodi e circa 26 000 archi l'aggregazione completa è eseguibile in memoria GPU e non introduce varianza di campionamento.

4.6 Rewiring a densità costante

Procedura. Ogni due step si generano coppie candidate a distanza 2 a partire da 500 nodi sorgente estratti casualmente (al più 5 candidati per sorgente, con sorgenti diverse a ogni step). Si selezionano fino a 50 coppie con score superiore a 0.65, in ordine decrescente; per ciascuna si rimuove l'arco esistente con lo score più basso, escludendo le rimozioni che porterebbero un nodo a grado nullo, tenendo conto delle rimozioni già decise nello stesso step, e quelle che coinvolgono fact-checker.

Motivazione.

- *Densità costante.* La prima versione aggiungeva archi con score superiore a una soglia e ne rimuoveva con score inferiore a un'altra. Poiché il link predictor è addestrato sugli archi esistenti, questi ricevono score elevati e le rimozioni risultavano di fatto assenti: la densità sarebbe cresciuta monotonamente e l'aumento di metriche come ECI e omofilia sarebbe stato confuso con la densificazione. Lo scambio (*swap*) mantiene $|E|$ costante, come nei modelli co-evolutivi di riferimento [11], e attribuisce ogni variazione delle metriche a una redistribuzione dei legami.
- *Candidati a distanza 2.* La restrizione alle coppie che condividono almeno un vicino corrisponde al meccanismo di chiusura triadica [1], che costituisce il processo prevalente di formazione dei legami nelle reti sociali, e riduce lo spazio di ricerca da $O(n^2)$ coppie a un insieme locale di cardinalità controllata.
- *Rimozione dei legami a score minimo.* Corrisponde all'osservazione per cui i legami tra individui dissimili si dissolvono più rapidamente [1, 21].
- *Limiti di velocità.* Il limite di 50 scambi ogni due step (circa lo 0.1% degli archi per step) mantiene la scala temporale della dinamica topologica più lenta di quella delle opinioni, in coerenza con l'osservazione che i legami sociali cambiano meno rapidamente delle opinioni espresse.

4.7 Selezione dei fact-checker: greedy esatto su obiettivo a soglia

Questa scelta è quella che si discosta maggiormente dall'impostazione iniziale del progetto, che prevedeva l'algoritmo CELF, e richiede quindi l'argomentazione più dettagliata.

Funzione obiettivo. L'effetto di un fact-checker sui vicini è governato dalle regole della Tabella 4: un suscettibile è protetto se $f_v^F \geq 0.10$ e $f_v^F \geq f_v^I$; un infetto è recuperato se $f_v^F \geq 0.25$. Si definisce l'insieme dei nodi coperti da un insieme di seed S:

$$\mathrm{Cov}(S) = \Big\{ v \notin S : \ (x_v = S \wedge f_v^F(S) \geq \tau_S \wedge f_v^F(S) \geq f_v^I) \ \vee \ (x_v = I \wedge f_v^F(S) \geq \tau_I) \Big\}, \quad (11)$$

con $\tau_S = 0.10$, $\tau_I = 0.25$, e si pone $g(S) = |\mathrm{Cov}(S)|$. La selezione risolve $\max_{|S| \leq k} g(S)$ con $k = 20$, restringendo i candidati ai nodi in stato S: la conversione di un infetto in fact-checker non è un intervento plausibile, e la conversione di un resistente impiegherebbe budget su un nodo già protetto.

Proposizione 4.1 (Non submodularità dell'obiettivo a soglia)**.** *La funzione g non è in generale submodulare.*

Dimostrazione. Si consideri un'istanza priva di fact-checker preesistenti in cui un nodo infetto v di grado 8 ha tra i propri vicini due nodi suscettibili a e b, i cui restanti vicini sono tutti resistenti, e quindi non coperti per definizione. Poiché $\lceil 0.25 \cdot 8 \rceil = 2$, il nodo v è coperto se e solo se a e b sono entrambi fact-checker. Posto $S = \emptyset$ e $S' = \{b\}$, si ha $g(S \cup \{a\}) - g(S) = 0$ e $g(S' \cup \{a\}) - g(S') = 1$, in violazione della (1) con $S \subseteq S'$. Lo stesso fenomeno si presenta per un suscettibile con due vicini infetti, per il quale la condizione $f_v^F \geq f_v^I$ richiede almeno due vicini fact-checker. □

La funzione presenta quindi rendimenti marginali crescenti in corrispondenza dei nodi che richiedono più di un fact-checker adiacente. La funzione non è neppure strettamente monotona: un suscettibile già coperto che venga selezionato come seed esce dall'insieme (11). La differenza rispetto al risultato di Kempe et al. risiede nel carattere deterministico delle soglie: con soglie uniformi in $[0, 1]$ la probabilità di attivazione di un nodo è lineare nella somma dei pesi dei vicini attivi e la funzione attesa risulta submodulare, mentre con soglie fissate la funzione di attivazione è a gradino. Ne derivano due conseguenze: *(i)* la valutazione lazy di CELF non è corretta, perché un guadagno calcolato in un'iterazione precedente non costituisce un limite superiore del guadagno corrente e un candidato potrebbe essere scartato erroneamente; *(ii)* il rapporto di approssimazione $1 - 1/e$ non è garantito per alcun algoritmo greedy.

Algoritmo adottato. Si utilizza il greedy completo, che a ogni iterazione rivaluta il guadagno marginale esatto di tutti i candidati. Il guadagno di un candidato dipende soltanto dal suo vicinato e può essere calcolato con contatori incrementali n_u^F aggiornati dopo ogni selezione; il costo complessivo è quindi $O\big(k \sum_{v \in C} \deg(v)\big) = O(k\,m)$, pari a circa 10^6 operazioni elementari per $k = 20$ e $m = 26\,246$. In caso di parità il criterio secondario è il progresso verso le soglie dei vicini non ancora coperti, $\sum_u 1/\deg(u)$, che attenua il problema dei rendimenti crescenti privilegiando i candidati che avvicinano più nodi alla soglia.

Tabella 6: Alternative per la selezione dei nodi di intervento.

Metodo	**Allineamento al meccanismo simulato**	**Garanzia teorica**	**Costo e determinismo**
Proxy (top-k per grado o PageRank)	Nessuno: ignora soglie e sovrapposizione dei vicinati	Nessuna	$O(n \log n)$; deterministico
MC-greedy / CELF su IC [13, 18]	Basso: ottimizza uno spread a cascata, non una copertura a soglia	$1 - 1/e - \varepsilon$ sotto IC	$R = 30$ simulazioni Monte Carlo per valutazione; stima rumorosa
Sketch (RIS, TIM, IMM) [3, 28, 29]	Non applicabile: richiede un modello di triggering	$1 - 1/e - \varepsilon$ con alta probabilità	Quasi lineare; stocastico
Greedy esatto sull'obiettivo (11) (adottato)	Completo: stesse soglie della macchina a stati	Nessuna (g non submodulare)	$O(km)$; deterministico ed esatto

Motivazione. La scelta privilegia la validità di costrutto rispetto alla garanzia formale. La garanzia $1 - 1/e$ di CELF si riferisce allo spread sotto IC, che non è la grandezza che determina l'esito nella simulazione: ottimizzare con garanzia una funzione obiettivo non corrispondente al meccanismo effettivo non fornisce alcuna garanzia sulla grandezza di interesse. L'obiettivo (11) è invece calcolato con le stesse soglie della macchina a stati, in modo esatto e senza errore di campionamento. CELF su IC (con probabilità $p_{uv} = 1/\deg(v)$, numeri casuali comuni tra i candidati e guadagni troncati a zero) resta disponibile come opzione di configurazione. Il limite principale dell'obiettivo adottato è la sua natura miope: considera l'effetto immediato sui vicini e non la dinamica successiva (rewiring, ricadute, risposte dell'LLM). La Sezione 6.4 verifica empiricamente l'accuratezza predittiva di tale approssimazione.

4.8 Metriche di segregazione

Si adottano due famiglie di metriche, complementari per costruzione.

Metriche strutturali (rispetto alla partizione fissa $\mathcal{C}_0$): la modularità (4) e l'Echo Chamber Index

$$\mathrm{ECI} = \frac{1}{|V^+|} \sum_{v \in V^+} \frac{|\{u \in N(v) : c_u = c_v\}|}{\deg(v)}, \qquad V^+ = \{v : \deg(v) > 0\}. \tag{12}$$

Metriche di opinione , definite sulla codifica $b(S) = 0$, $b(I) = +1$, $b(R) = b(F) = -1$, coerente con il verso delle perturbazioni dell'Eq. (6):

- *opinion homophily* $H = |\{(u, v) \in E : b_u = b_v\}|/|E|$, da confrontare con il valore atteso H_0 dell'Eq. (3);
- *belief assortativity* r, correlazione di Pearson tra b_u e b_v calcolata su entrambi gli orientamenti di ogni arco [23];
- *belief polarisation* $\mathrm{BP} = \mathrm{Var}(b)/\big((b_{\max} - b_{\min})/2\big)^2$.

L'adozione di entrambe le famiglie è motivata dal fatto che ECI e Q non dipendono dalle opinioni: un rewiring che raggruppa agenti con la stessa opinione appartenenti a comunità diverse riduce l'ECI pur aumentando la segregazione ideologica. Viceversa, le metriche di opinione non rilevano il rafforzamento delle comunità disciplinari indipendente dalle opinioni.

Osservazione 4.1 (Natura composizionale di BP). Con la codifica adottata, indicando con p_I e p_{RF} le frazioni di nodi in I e in $R \cup F$, si ha $\mathrm{Var}(b) = p_I + p_{RF} - (p_I - p_{RF})^2$ e $(b_{\max} - b_{\min})/2 = 1$. L'indice BP è dunque una funzione delle sole numerosità degli stati e non dipende dalla topologia. Ad esempio, allo step 99 ($p_I = 0.4064$, $p_{RF} = 0.3980$) la formula restituisce 0.8043, valore coincidente con quello registrato. BP aumenta ogni volta che nodi neutrali assumono una qualunque posizione, inclusa quella resistente, e va interpretato come indice di schieramento della popolazione e non come misura di polarizzazione della rete.

5 Disegno sperimentale

5.1 Fasi e parametri

L'esperimento si articola in quattro fasi: Fase 0 (campionamento, comunità, metriche di base), Fase 1 (inizializzazione degli agenti e dei pazienti zero), Fase 2 (100 step di co-evoluzione, step 0–99, eseguiti in due sessioni da 50 step con ripresa da checkpoint), Fase 3 (30 step post-intervento, step 100–129). La Tabella 7 riporta i parametri principali.

Tabella 7: Parametri della configurazione sperimentale.

Componente	Parametro	Valore
Dati	Sottografo (Forest Fire, p_f)	5 000 nodi, 26 246 archi, $p_f = 0.5$
Agenti	Pazienti zero; attivazione per step	15% (750 nodi); $\rho = 0.15$
	Finestra di memoria del feed	ultimi 3 post dei vicini
LLM	Modello; temperatura; richieste concorrenti	Llama 3 8B Instruct AWQ; 0.7; 150
Soglie	θ_v; esposizione minima per resistenza	$\mathcal{N}(0.3, 0.1^2)$; 0.12
	Ricaduta $R \to I$	$f^I \geq 0.6$, $s > 0.8$
	Inoculazione $S \to R$; recupero $I \to R$	$f^F \geq 0.10$; $f^F \geq 0.25$
GNN	Dimensioni; learning rate; epoche per step	128/128; 10^{-3}; 15
Rewiring	Intervallo; scambi; soglia di aggiunta	2 step; 50; 0.65
	Candidati	500 sorgenti $\times$ 5 coppie a distanza 2
Intervento	Budget; soglia di attivazione	$k = 20$; infection rate ≥ 0.4
Riproducibilità	Seed globale	42

5.2 Disegno accoppiato intervento/controllo

Un confronto prima/dopo all'interno di una singola simulazione confonderebbe l'effetto dell'intervento con l'evoluzione spontanea della rete, che prosegue anche in assenza di trattamento. La Fase 3 è quindi eseguita due volte a partire dallo stesso checkpoint dello step 99 e per lo stesso numero di step: una simulazione con l'iniezione dei fact-checker e una simulazione di controllo senza iniezione. L'effetto dell'intervento su una grandezza Y è stimato come differenza tra le due simulazioni allo stesso step,

$$\hat{\Delta}_Y(t) = Y^{\text{int}}(t) - Y^{\text{ctrl}}(t). \tag{13}$$

Il seed per richiesta, derivato dal contenuto del prompt, fa sì che le due simulazioni ricevano risposte identiche finché i prompt coincidono: la tecnica corrisponde all'uso di numeri casuali comuni, che riduce la varianza della differenza stimata rispetto a due esecuzioni indipendenti. All'inizio della Fase 3 l'infection rate è pari a 0.4064, superiore alla soglia di attivazione: l'intervento non è stato forzato.

6 Risultati e discussione

6.1 Validazione del campionamento

Tabella 8: Confronto tra la componente connessa principale del grafo originale e il sottografo campionato.

Metrica	Originale (LCC)	Sottografo	Variazione relativa
Nodi	232 865	5 000	−97.9%
Archi	961 883	26 246	−97.3%
Grado medio $\langle k \rangle$	8.3	10.5	+27.1%
Grado massimo	382	119	−68.8%
Deviazione standard del grado	13.4	9.7	−27.1%
Clustering medio	0.7204	0.6988	−3.0%
Modularità (Label Propagation)	0.6957	0.8265	+18.8%
Densità	3.5×10^{-5}	2.1×10^{-3}	×59

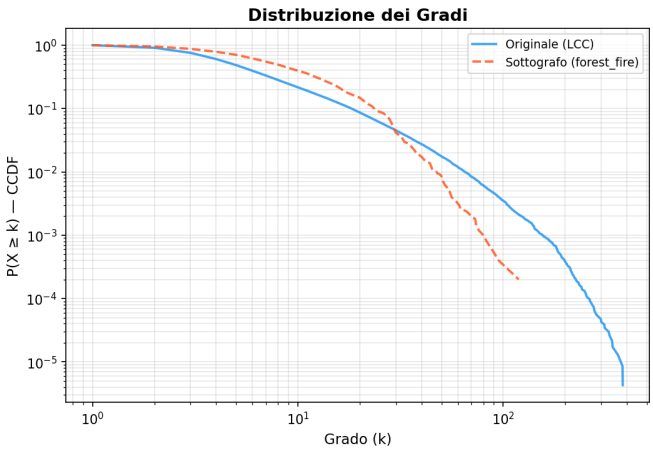


Figura 2: Funzione di distribuzione cumulativa complementare del grado, in scala doppiamente logaritmica, per il grafo originale (LCC) e per il sottografo.

Il coefficiente di clustering è preservato con uno scostamento del 3%, condizione rilevante per il rewiring basato su chiusura triadica. La distribuzione dei gradi mantiene una coda pesante (Figura 2), ma con un troncamento: il grado massimo si riduce da 382 a 119 e la coda del sottografo decresce più rapidamente oltre $k \approx 30$. Il campione sovrarappresenta i gradi intermedi ($\langle k \rangle$ +27%) e sottorappresenta gli hub estremi. L'aumento della modularità (+18.8%) e della densità sono effetti attesi della riduzione di scala. Ai fini dello studio, la conseguenza principale è che il ruolo degli hub estremi nella diffusione risulta attenuato rispetto alla rete completa; i risultati relativi all'efficacia dei nodi centrali vanno quindi considerati riferiti a una rete con coda dei gradi troncata. Il calcolo delle metriche richiede circa 114 s sulla LCC e 0.4 s sul sottografo.

6.2 Dinamica di diffusione (Fase 2)

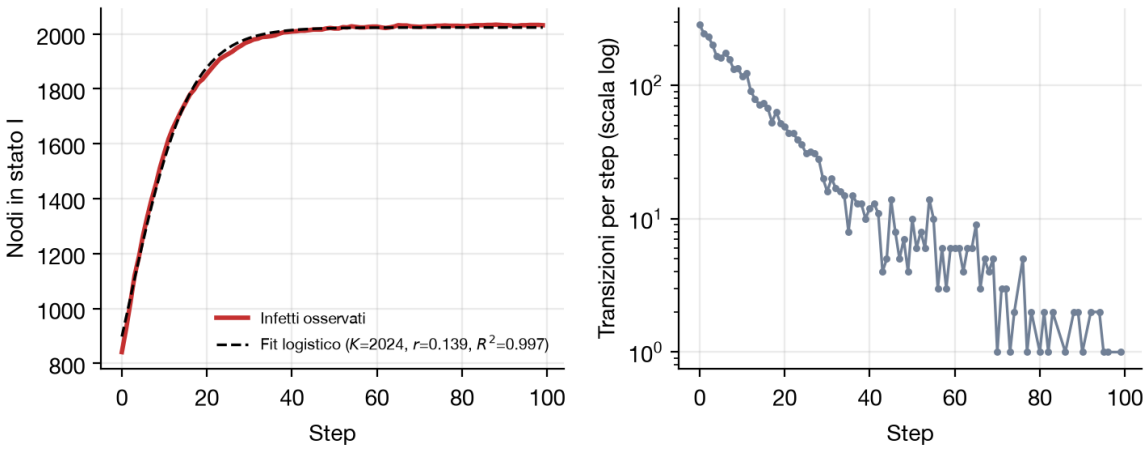


Figura 3: Sinistra: numero di infetti nella Fase 2 e curva logistica stimata ai minimi quadrati. Destra: transizioni di stato per step in scala logaritmica (gli step con zero transizioni non sono rappresentati).

La popolazione infetta cresce da 841 a 2 032 nodi; i suscettibili scendono da 3 965 a 978, i resistenti salgono da 194 a 1 990, e gli infetti superano i suscettibili allo step 16. L'adattamento della curva logistica $I(t) = K/(1 + \frac{K-I_0}{I_0}e^{-rt})$ ai 100 punti della Fase 2 fornisce $K = 2\,024$ (40.5% dei nodi), $r = 0.139$ step^{-1} e $R^2 = 0.997$ (Figura 3). Il numero di transizioni per step

decresce da 285 (step 0) a una media di 1.08 negli ultimi 25 step; il 78.3% delle 3 422 transizioni della Fase 2 avviene nei primi 20 step.

In relazione a **RQ1**, il dato rilevante non è la forma logistica in sé, attesa per qualunque processo di contagio con popolazione finita, ma il livello di saturazione. Il modello SI (2) prevede la saturazione dell'intera popolazione; la dinamica osservata si arresta invece al 40.5%, in modo qualitativamente coerente con il modello SIR, nel quale il compartimento R sottrae nodi al processo. Nel modello simulato concorrono due meccanismi: la crescita del compartimento resistente (+1 796 nodi durante la Fase 2, per resistenza attiva o autocorrezione) e l'eterogeneità delle soglie, per cui i nodi con θ_v^{eff} superiore alla frazione di vicini infetti raggiungibile restano in S indefinitamente. La popolazione infetta si stabilizza entro circa 40 step: tra lo step 40 e lo step 99 varia dell'1.1%.

Si osserva inoltre che la scala temporale della crescita, $1/r \approx 7.2$ step, è dello stesso ordine del tempo medio di attesa prima dell'attivazione di un nodo, $1/\rho \approx 6.7$ step. Il dato è compatibile con l'ipotesi che la velocità di diffusione sia limitata dal calendario di attivazione più che dalla pressione dei vicini; la verifica richiederebbe esecuzioni con valori diversi di ρ.

6.3 Co-evoluzione e segregazione (Fase 2)

Tabella 9: Metriche strutturali e di opinione durante la Fase 2. H_0: omofilia attesa per assegnazione casuale (Eq. 3); $\rho_{\text{et}} = (1-H)/(1-H_0)$: rapporto tra archi eterofili osservati e attesi.

Step	**ECI**	Q	H	H_0	ρ_{et}	r
0	0.832	0.828	0.629	0.659	1.087	0.268
4	0.834	0.830	0.585	0.465	0.777	0.284
10	0.835	0.833	0.615	0.357	0.599	0.353
25	0.840	0.841	0.708	0.340	0.442	0.464
50	0.850	0.855	0.762	0.355	0.369	0.550
99	0.874	0.877	0.814	0.362	0.291	0.659

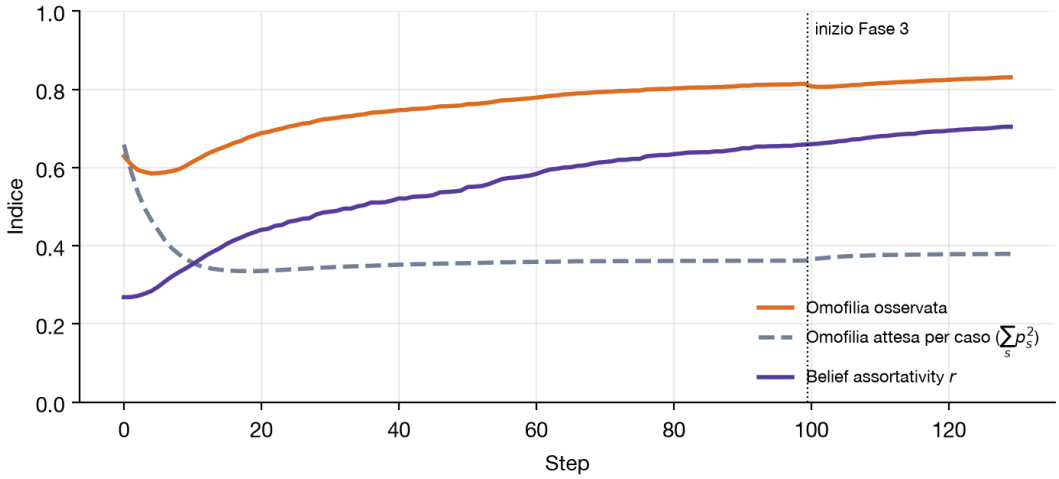


Figura 4: Omofilia di opinione osservata, omofilia attesa in caso di assegnazione casuale degli stati e belief assortativity, step 0–129.

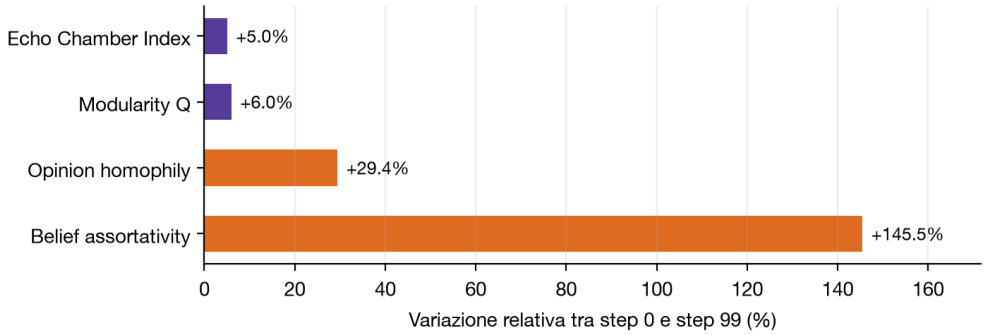


Figura 5: Variazione relativa delle metriche strutturali (viola) e di opinione (arancione) tra lo step 0 e lo step 99.

Segregazione di opinione. Allo step 0 l'omofilia osservata (0.629) è inferiore a quella attesa per caso (0.659): la rete non presenta omofilia di opinione, e la lieve eterofilia ($\rho_{\text{et}} = 1.087$) è coerente con la selezione dei pazienti zero tra i nodi centrali, i cui vicini sono in prevalenza suscettibili. Allo step 99 gli archi tra stati diversi sono il 29.1% di quelli attesi per caso. Secondo il test di omofilia [1], la rete passa quindi da una condizione di assenza di omofilia a una condizione di omofilia marcata, prodotta interamente dalla dinamica. La belief assortativity, che incorpora la correzione rispetto al caso, cresce da 0.268 a 0.659 (+145.5%).

La Tabella 9 consente inoltre di correggere una lettura del solo indice H. Nei primi quattro step H diminuisce da 0.629 a 0.585, il che suggerirebbe una riduzione iniziale dell'omofilia. Nello stesso intervallo, tuttavia, H_0 scende da 0.659 a 0.465 perché la frazione di suscettibili si riduce, e il rapporto ρ_{et} scende da 1.087 a 0.777: l'omofilia relativa al caso aumenta fin dal primo step. La diminuzione di H è un effetto della variazione della composizione degli stati e non della struttura dei legami. Il caso illustra la necessità di metriche corrette rispetto alla distribuzione marginale, quali ρ_{et} o r.

Segregazione strutturale. ECI e Q crescono in modo regolare e monotono (+5.0% e +6.0% in 100 step). La crescita è di oltre un ordine di grandezza inferiore a quella della belief assortativity (Figura 5). In 100 step il rewiring sostituisce 2 500 archi, il 9.5% del totale; la topologia è dunque modificata in misura limitata, mentre la distribuzione delle opinioni sui legami muta in modo sostanziale.

In relazione a **RQ2**, la co-evoluzione incrementa entrambe le forme di segregazione, ma la componente di opinione domina quella strutturale. Ne segue che una valutazione basata sul solo ECI sottostimerebbe la formazione di echo chamber. Due cautele interpretative sono necessarie.

1. *Contributo del generatore di candidati.* I candidati al rewiring sono coppie a distanza 2; in un grafo con clustering 0.70 e modularità 0.83 tali coppie appartengono prevalentemente alla stessa comunità. Una parte dell'aumento di ECI e Q può pertanto derivare dalla chiusura triadica in sé, indipendentemente dalle opinioni. La quantificazione richiede un esperimento di ablazione con rewiring tra coppie a distanza 2 scelte casualmente.

2. *Selezione e influenza.* Con i dati disponibili non è possibile separare il contributo della selezione (rewiring guidato dagli embedding) da quello dell'influenza (contagio a soglia) all'aumento di r. Il contributo della selezione è verosimilmente limitato dal ridotto numero di archi sostituiti, ma la stima richiede una simulazione con rewiring disattivato o indipendente dalle opinioni.

Frammentazione. Il numero di componenti connesse passa da 1 a 86 allo step 99 e a 154 allo step 129, identico nelle due simulazioni della Fase 3. Il vincolo di sicurezza impedisce l'isolamento di singoli nodi ma non il distacco di piccoli gruppi. Sul campione dei 150 nodi

di grado massimo il numero di archi interni passa da 1 345 a 1 588 (+18%) a densità globale invariata: i nuovi legami tendono a concentrarsi sui nodi centrali (Figura 6).

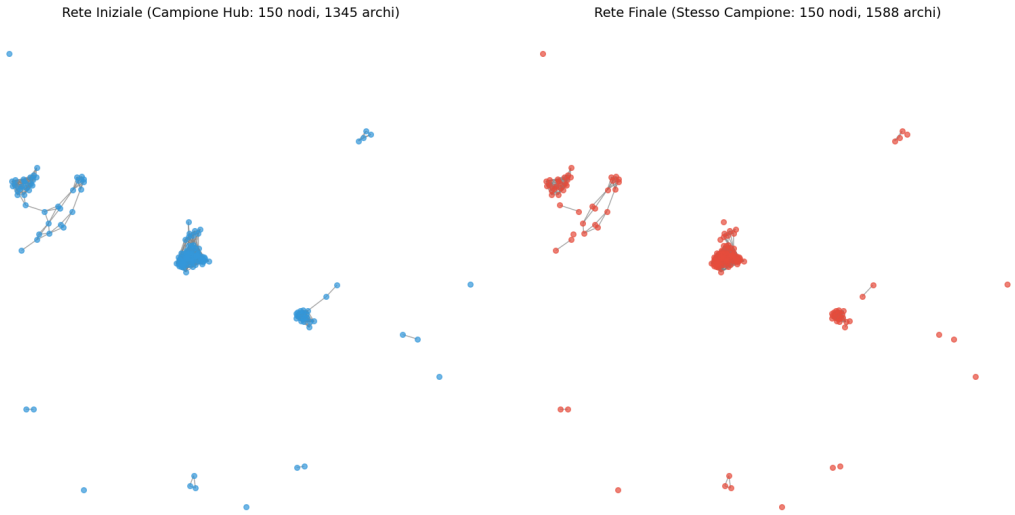


Figura 6: Sottografo indotto dai 150 nodi di grado massimo allo step iniziale (sinistra) e allo step 129 della simulazione di controllo (destra), con posizioni fissate.

6.4 Effetto dell'intervento (Fase 3)

Tabella 10: Confronto allo step 129 tra la simulazione con 20 fact-checker e la simulazione di controllo, avviate dal medesimo checkpoint.

Grandezza	**Intervento**	**Controllo**	**Effetto $\hat{\Delta}$**
Nodi S	798	974	−176
Nodi I	2 020	2 024	−4
Nodi R	2 162	2 002	+160
Nodi F	20	0	+20
Transizioni negli step 100–129	177	17	+160
Belief assortativity r	0.7042	0.6922	+0.0119
Opinion homophily H	0.8305	0.8306	−0.0001
Belief polarisation	0.8394	0.8052	+0.0342
Echo Chamber Index	0.8855	0.8858	−0.0003
Modularità Q	0.8831	0.8835	−0.0004

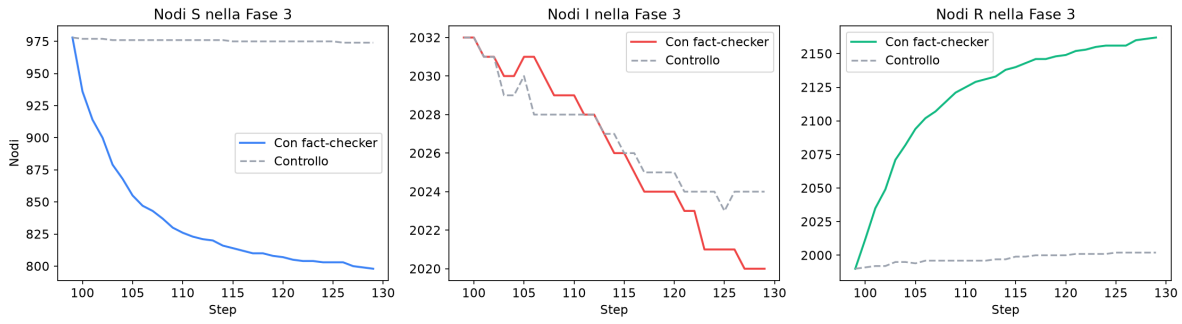


Figura 7: Nodi suscettibili, infetti e resistenti negli step 99–129 nella simulazione con intervento (linea continua) e di controllo (linea tratteggiata). Le scale verticali differiscono tra i pannelli.

Protezione dei suscettibili. L'effetto principale riguarda i suscettibili: escludendo i 20 nodi convertiti in fact-checker, 156 suscettibili in più rispetto al controllo transitano in R, pari al 16.0% dei 978 suscettibili presenti all'inizio della Fase 3. La differenza è circa nove volte superiore al numero totale di transizioni spontanee della simulazione di controllo (17), e non è quindi attribuibile alla variabilità della dinamica.

Accuratezza della stima ex ante. La selezione ha stimato una copertura di 162 nodi; la differenza osservata nei resistenti è di 160 nodi (errore relativo 1.2%). Nonostante la natura miope dell'obiettivo (11), la stima predice con buona approssimazione l'effetto realizzato nell'orizzonte di 30 step. La ragione è che le condizioni di inoculazione dipendono dalle frazioni di vicini F e I, che variano poco nella fase quasi stazionaria, e che la regola richiede solo l'assenza di una proposta di infezione da parte dell'LLM.

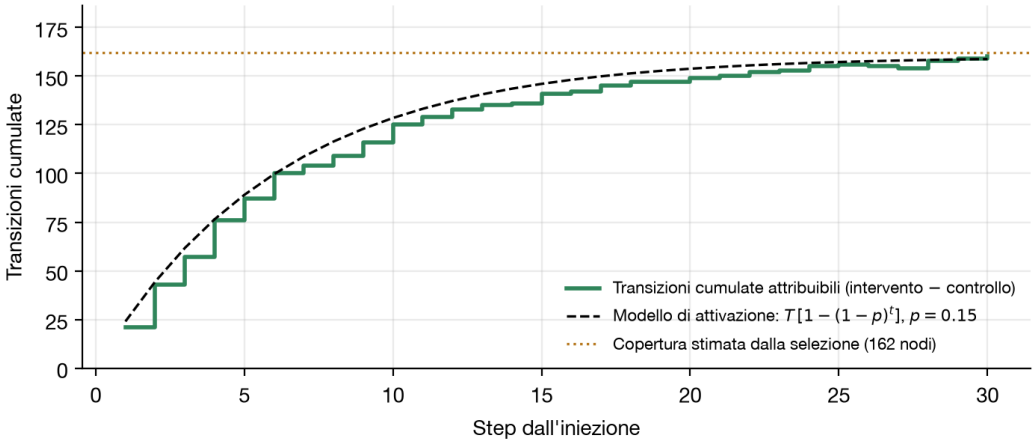


Figura 8: Transizioni cumulate attribuibili all'intervento (differenza tra le due simulazioni) e previsione del modello di attivazione geometrica con $T = 160$ e $p = \rho = 0.15$.

Dinamica temporale. Un nodo coperto può transitare solo quando viene attivato, evento che si verifica con probabilità $\rho = 0.15$ per step. Se la copertura resta stabile, la frazione attesa di nodi coperti già attivati dopo t step è $1 - (1 - \rho)^t$, pari a 0.803 per $t = 10$ e 0.992 per $t = 30$. Le transizioni attribuibili all'intervento nei primi 10 step sono 125 su 160 (78.1%), in accordo con la previsione (Figura 8). La dinamica dell'intervento è quindi spiegata dal calendario di attivazione degli agenti: l'intervento esaurisce il proprio effetto quando tutti i nodi coperti sono stati attivati almeno una volta. Alla fine della simulazione i fact-checker raggiungono direttamente 194 nodi, ma solo 5 nodi soddisfano ancora le condizioni di copertura.

Effetto sugli infetti. La differenza sugli infetti (-4) si forma negli ultimi 15 step ed è inferiore alla variazione spontanea degli infetti nella simulazione di controllo nello stesso intervallo (-8 nodi). L'effetto non è distinguibile dalla variabilità della dinamica. Il risultato è conseguenza diretta delle regole del modello: il recupero di un infetto richiede che almeno un quarto dei suoi vicini sia fact-checker, condizione che con 20 seed scelti tra i suscettibili non è soddisfatta in modo significativo. In termini epidemiologici, l'intervento opera come immunizzazione mirata dei suscettibili [26] e non come trattamento degli infetti.

Metriche di opinione e strutturali. La belief assortativity aumenta di 0.012 rispetto al controllo: i nodi protetti diventano resistenti in prossimità dei fact-checker e di altri resistenti, rafforzando i gruppi di opinione esistenti. L'aumento di BP (+0.034) è interamente spiegato dalla variazione delle numerosità secondo l'Osservazione 4.1: con $p_I = 0.404$ e $p_{RF} = 0.4364$ la

formula restituisce 0.8393, valore registrato. L'aumento di BP non indica quindi una maggiore polarizzazione della rete, ma il passaggio di nodi neutrali a una posizione definita. ECI e modularità differiscono di meno di 5×10^{-4} tra le due simulazioni: nell'orizzonte osservato l'intervento agisce sugli stati e non sulla topologia.

In relazione a **RQ3**, un intervento tardivo con budget dello 0.4% produce un effetto netto e misurabile sulla popolazione suscettibile residua e nessun effetto distinguibile sulla popolazione infetta consolidata. Con le regole adottate, il fact-checking svolge una funzione preventiva e non correttiva; la tempistica dell'intervento rispetto alla curva di diffusione è quindi un parametro rilevante quanto il budget.

6.5 Prestazioni computazionali

Tabella 11: Costi computazionali osservati e stimati.

Operazione	**Costo**
Step co-evolutivo con LLM reale	circa 12 minuti su una T4; circa 6 minuti con parallelismo tensoriale su due T4
Fase 2 (100 step)	circa 10 ore (stima: 100 step $\times$ 6 minuti), in due sessioni da 50 step con ripresa da checkpoint
Fase 3 (2 simulazioni da 30 step)	circa 3 ore per simulazione (stima)
Invocazioni LLM per step	al più 750 (attivazione del 15%), ridotte dall'esclusione dei suscettibili non esposti
Selezione dei fact-checker	$O(km) \approx 10^6$ operazioni elementari; tempo trascurabile rispetto a uno step
Metriche topologiche	riutilizzate se l'impronta dell'insieme di archi è invariata (circa 13 ms su 26 000 archi)
Link predictor	loss BCE da 0.816 (step 0) a 0.360 (step 99); valore di riferimento per un classificatore non informativo: $\ln 2 \approx 0.693$

Il costo dominante è l'inferenza dell'LLM, che rappresenta la quasi totalità del tempo di uno step: GNN, rewiring e metriche hanno costi di ordini di grandezza inferiori. Le scelte architetturali orientate al requisito R2 (aggiornamento sincrono con invio parallelo, server con batching continuo, attivazione parziale, quantizzazione) hanno pertanto l'effetto maggiore sul tempo complessivo. Il valore di 0.36 raggiunto dalla loss del link predictor, inferiore a $\ln 2$, indica che il modello separa gli archi esistenti dalle coppie casuali; la stabilizzazione dopo circa 30 step è coerente con la stabilizzazione degli stati.

6.6 Minacce alla validità

Validità interna. Ciascuna configurazione è stata eseguita una sola volta: con un costo di circa 6 minuti per step non è stato possibile replicare le simulazioni con seed diversi, e non sono disponibili intervalli di confidenza. Gli effetti di grande entità (protezione dei suscettibili) sono robusti rispetto alla variabilità osservata nel controllo; gli effetti piccoli (infetti, assortatività) richiedono repliche. Il seed per richiesta rende ripetibili le risposte a parità di prompt, ma vLLM non garantisce il determinismo completo in presenza di batching variabile.

Validità di costrutto. ECI e Q sono calcolati rispetto alla partizione dello step 0 e non rilevano la formazione di nuove comunità. BP misura la composizione degli stati e non la struttura della rete (Osservazione 4.1). L'assegnazione dei profili comportamentali in base all'identificativo della comunità modulo 4 è arbitraria rispetto al contenuto delle comunità. L'obiettivo di selezione dei fact-checker è miope rispetto alla dinamica successiva.

Validità esterna. La rete di co-autoraggio è utilizzata come approssimazione di una rete sociale; il campione di 5 000 nodi presenta una coda dei gradi troncata; il comportamento degli agenti dipende dal modello linguistico (8 miliardi di parametri, quantizzato) e dalla formulazione dei prompt, e risultati diversi potrebbero emergere con modelli o prompt differenti.

7 Conclusioni e sviluppi futuri

Il lavoro ha presentato un framework in cui cognizione generativa, topologia e intervento evolvono in un unico ciclo di aggiornamento, giustificando ciascuna scelta rispetto alle alternative. Le scelte principali sono: il ciclo chiuso con aggiornamento sincrono e attivazione parziale, necessario per l'accoppiamento bidirezionale e la trattabilità dell'inferenza; il modello Linear Threshold esteso, motivato dalla natura complessa del contagio di opinione; GraphSAGE, per l'uso delle feature come canale di accoppiamento e per l'induttività; il rewiring a densità costante, che isola la redistribuzione dei legami dalla densificazione; il greedy esatto su un obiettivo allineato alla macchina a stati, preferito a CELF in quanto l'obiettivo non è submodulare (Proposizione 4.1) e lo spread sotto IC non corrisponde al meccanismo simulato.

Le risposte alle domande di ricerca sono le seguenti.

RQ1 La diffusione segue una curva logistica ($R^2 = 0.997$) con saturazione al 40.5%, coerente qualitativamente con un modello SIR più che con un modello SI; la scala temporale della crescita è dello stesso ordine di quella del calendario di attivazione.

RQ2 La co-evoluzione produce omofilia di opinione assente all'inizio (rapporto tra archi eterofili osservati e attesi da 1.087 a 0.291; belief assortativity +145.5%), mentre la segregazione strutturale cresce del 5–6%. Le metriche strutturali da sole sottostimano il fenomeno.

RQ3 Venti fact-checker introdotti a dinamica stabilizzata proteggono il 16% dei suscettibili residui, con un effetto prevedibile ex ante (162 nodi stimati, 160 osservati) e una cinetica spiegata dal calendario di attivazione; l'effetto sugli infetti non è distinguibile dalla variabilità della dinamica.

Gli sviluppi previsti derivano direttamente dalle limitazioni discusse: *(i)* repliche con seed diversi per stimare intervalli di confidenza; *(ii)* esperimenti di ablazione (rewiring disattivato, rewiring indipendente dalle opinioni, candidati casuali a distanza 2) per separare selezione, influenza e contributo della chiusura triadica; *(iii)* variazione della tempistica dell'intervento e del budget, per determinare le condizioni in cui l'intervento riduce anche la popolazione infetta; *(iv)* un obiettivo di selezione non miope, ad esempio basato su simulazioni in avanti della macchina a stati con risposte dell'LLM approssimate; *(v)* un vincolo di connettività sulle rimozioni del rewiring; *(vi)* il confronto tra modelli linguistici e formulazioni dei prompt differenti.

Riferimenti bibliografici

[1] N. Gabriele, M. Capalbo. *Appunti di Social Media and Network Analysis.* Materiale didattico, Corso di Laurea Magistrale in Ingegneria Informatica, Università della Calabria, A.A. 2023/2024.

[2] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, E. Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, P10008, 2008.

[3] C. Borgs, M. Brautbar, J. Chayes, B. Lucier. Maximizing social influence in nearly optimal time. In *Proceedings of the ACM-SIAM Symposium on Discrete Algorithms (SODA)*, 2014.

[4] D. Centola, M. Macy. Complex contagions and the weakness of long ties. *American Journal of Sociology*, 113(3):702–734, 2007.

[5] M. Cinelli, G. De Francisci Morales, A. Galeazzi, W. Quattrociocchi, M. Starnini. The echo chamber effect on social media. *Proceedings of the National Academy of Sciences*, 118(9):e2023301118, 2021.

[6] S. Fortunato, M. Barthélemy. Resolution limit in community detection. *Proceedings of the National Academy of Sciences*, 104(1):36–41, 2007.

[7] M. Granovetter. Threshold models of collective behavior. *American Journal of Sociology*, 83(6):1420–1443, 1978.

[8] A. Grattafiori et al. The Llama 3 herd of models. arXiv:2407.21783, 2024.

[9] A. Grover, J. Leskovec. node2vec: Scalable feature learning for networks. In *Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2016.

[10] W. L. Hamilton, R. Ying, J. Leskovec. Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[11] P. Holme, M. E. J. Newman. Nonequilibrium phase transition in the coevolution of networks and opinions. *Physical Review E*, 74:056108, 2006.

[12] W. Hu, M. Fey, M. Zitnik, Y. Dong, H. Ren, B. Liu, M. Catasta, J. Leskovec. Open Graph Benchmark: Datasets for machine learning on graphs. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[13] D. Kempe, J. Kleinberg, É. Tardos. Maximizing the spread of influence through a social network. In *Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 137–146, 2003.

[14] W. O. Kermack, A. G. McKendrick. A contribution to the mathematical theory of epidemics. *Proceedings of the Royal Society A*, 115(772):700–721, 1927.

[15] T. N. Kipf, M. Welling. Semi-supervised classification with graph convolutional networks. In *International Conference on Learning Representations (ICLR)*, 2017.

[16] W. Kwon, Z. Li, S. Zhuang, Y. Sheng, L. Zheng, C. H. Yu, J. E. Gonzalez, H. Zhang, I. Stoica. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the ACM Symposium on Operating Systems Principles (SOSP)*, 2023.

[17] J. Leskovec, C. Faloutsos. Sampling from large graphs. In *Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 631–636, 2006.

[18] J. Leskovec, A. Krause, C. Guestrin, C. Faloutsos, J. VanBriesen, N. Glance. Cost-effective outbreak detection in networks. In *Proceedings of the ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 420–429, 2007.

[19] D. Liben-Nowell, J. Kleinberg. The link-prediction problem for social networks. *Journal of the American Society for Information Science and Technology*, 58(7):1019–1031, 2007.

[20] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang, G. Xiao, X. Dang, C. Gan, S. Han. AWQ: Activation-aware weight quantization for on-device LLM compression and acceleration. In *Proceedings of Machine Learning and Systems (MLSys)*, 2024.

[21] M. McPherson, L. Smith-Lovin, J. M. Cook. Birds of a feather: Homophily in social networks. *Annual Review of Sociology*, 27:415–444, 2001.

[22] G. L. Nemhauser, L. A. Wolsey, M. L. Fisher. An analysis of approximations for maximizing submodular set functions—I. *Mathematical Programming*, 14:265–294, 1978.

[23] M. E. J. Newman. Mixing patterns in networks. *Physical Review E*, 67:026126, 2003.

[24] M. E. J. Newman. Modularity and community structure in networks. *Proceedings of the National Academy of Sciences*, 103(23):8577–8582, 2006.

[25] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, M. S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the ACM Symposium on User Interface Software and Technology (UIST)*, 2023.

[26] R. Pastor-Satorras, A. Vespignani. Immunization of complex networks. *Physical Review E*, 65:036104, 2002.

[27] U. N. Raghavan, R. Albert, S. Kumara. Near linear time algorithm to detect community structures in large-scale networks. *Physical Review E*, 76:036106, 2007.

[28] Y. Tang, X. Xiao, Y. Shi. Influence maximization: Near-optimal time complexity meets practical efficiency. In *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2014.

[29] Y. Tang, Y. Shi, X. Xiao. Influence maximization in near-linear time: A martingale approach. In *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2015.

[30] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio. Graph attention networks. In *International Conference on Learning Representations (ICLR)*, 2018.